

PHÂN TÍCH KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU

Họ tên: Mã SV:

PHÂN TÍCH KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU

Câu 1. Cho tập dữ liệu:

ID	Tuổi	Lương	Điểm	Giới tính	Mua hàng
1	25	8000	7.5	Nam	Yes
2	30	?	8.0	Nữ	No
3	22	5000	6.5	Nam	Yes
4	40	15000	9.0	Nữ	Yes
5	35	-2000	7.0	Nam	No
6	?	7000	6.0	Nữ	Yes
7	29	8500	8.5	Nam	Yes
8	50	30000	9.5	Nữ	Yes
9	27	8200	?	Nam	No
10	31	7800	7.8	Nữ	Yes

Câu hỏi 1 (Data Overview). Xác định: số lượng mẫu, số thuộc tính, kiểu dữ liệu (categorical / numerical)

Câu hỏi 2 (Descriptive Statistics). Thống kê mô tả: Mean, Median, Mode cho: Tuổi, Lương, Điểm

Câu hỏi 3 (Distribution Analysis). Phân tích phân phối:

- + Vẽ histogram (Tuổi) và boxplot (Lương).
- + Nhận xét dạng phân phối (lệch trái/phải, đối xứng).
- + Xác định outlier và dữ liệu bất thường (nếu có).

Câu hỏi 4 (Relationship Analysis). Phân tích quan hệ:

- + Vẽ scatter plot giữa Tuổi và Lương
- + Nhận xét xu hướng (dương/âm/không rõ)
- + Phát hiện outlier
- + Đề xuất tiền xử lý trước khi modeling

Câu hỏi 5 (EDA - Missing Data). Xác định giá trị thiếu

- + Xác định các giá trị thiếu trong dataset
- + Tính số lượng và tỷ lệ missing cho từng thuộc tính
- + Nhận xét mức độ ảnh hưởng của missing data
- + Đề xuất phương pháp xử lý phù hợp

Câu hỏi 6 (Missing Data - Processing). Với các thuộc tính có giá trị thiếu:

- + Xác định vị trí và số lượng missing.
- + Áp dụng ít nhất 2 phương pháp điền giá trị (mean/median/khác).
- + So sánh và chọn phương pháp phù hợp.

Câu hỏi 7 (Data Quality). Xác định các giá trị không hợp lý trong dữ liệu (ví dụ: giá trị âm, sai miền giá trị) và đề xuất cách xử lý.

Câu hỏi 8 (Outlier Detection). Phát hiện các outlier trong dữ liệu bằng phương pháp IQR hoặc Z-score cho cột lương và nêu rõ các giá trị đó.

PHÂN TÍCH KHÁM PHÁ VÀ TIỀN XỬ LÝ DỮ LIỆU

Câu hỏi 9 (Normalization). Chuẩn hóa thuộc tính **Lương** bằng phương pháp Z-score và nhận xét sự thay đổi của dữ liệu.

Câu hỏi 10 (Encoding). Thực hiện mã hóa: Giới tính bằng one-hot encoding, Mua hàng bằng binary encoding (Yes/No $\rightarrow$ 1/0). Viết kết quả dữ liệu sau khi mã hóa.

Câu hỏi 11 (Feature Selection). Xác định các thuộc tính nên giữ hoặc loại bỏ và giải thích dựa trên: mức độ liên quan, dữ liệu thiếu / lỗi, ảnh hưởng đến mô hình

Câu hỏi 12 (Data Reduction). Đề xuất một phương pháp giảm chiều dữ liệu (ví dụ: loại bỏ thuộc tính, PCA,...) và giải thích khi nào nên áp dụng với dataset này.

Câu 2. Giả sử tập dữ liệu dùng cho phân tích có thuộc tính tuổi. Các giá trị tuổi của các mẫu dữ liệu (đã được sắp xếp theo thứ tự tăng dần) như sau:

13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70

Anh/chị hãy:

- Tính giá trị trung bình, trung vị, mode của tập dữ liệu.
- Xác định tứ phân vị thứ nhất (Q_1) và tứ phân vị thứ ba (Q_3) (xấp xỉ nếu cần).
- Vẽ biểu đồ hộp (boxplot) cho tập dữ liệu trên và nhận xét về phân bố dữ liệu.
- Rời rạc hóa dữ liệu dùng phương pháp chia đều, hay tần số với $k = 4$.

Câu 3. Dựa trên các giá trị trong bảng dưới đây, hãy cho biết các giá trị này được đo lường theo thang đo nào tương ứng trong các thang đo sau: (1) thang đo định danh, (2) thang đo thứ bậc, (3) thang đo khoảng, và (4) thang đo tỷ lệ? Sau đó, trong các đại lượng $W_1, W_2, W_3, W_4, W_5, W_6$, hãy xác định đại lượng nào biểu diễn cùng một thang đo với $V(.)$?

	A	B	C	D	E
$V(.)$	1	2	3	4	5
$W_1(.)$	100	200	300	400	500
$W_2(.)$	10	11	12	13	14
$W_3(.)$	8	13	45	6	7
$W_4(.)$	1	4	9	16	25
$W_5(.)$	-10	-8	-6	-4	-2
$W_6(.)$	3	6	9	12	15

---o0o---

(Hết)